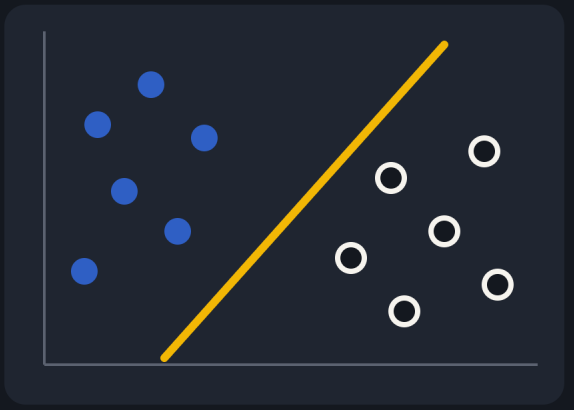


Прошлый раз: регрессия — прямая через точки



Сегодня: прямая разделяет классы

Логистическая регрессия Классификация

Преподаватель: **Вересников Артем**, MLE в WB

Задача классификации

Объект → класс $y \in \{0, 1\}$. Хотим не просто класс, а **вероятность** класса 1.

Спам

Письмо → «спам» или «не спам».

Фрод

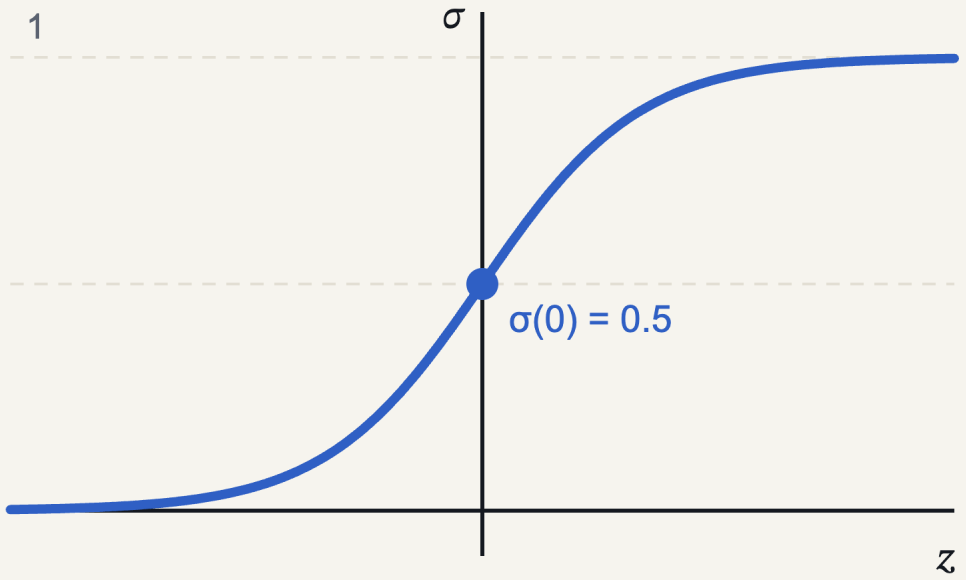
Транзакция → «мошенническая» или «нормальная».

Медицина

Снимок → «болен» или «здоров».

Почему не взять линейную регрессию на метках 0 и 1?

Сигмоида



$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Модель: $z = w_1x_1 + \ldots + w_Dx_D + w_0$, затем $p = \sigma(z)$.

- любое $z \to$ число от 0 до 1
- $\sigma(-z) = 1 - \sigma(z)$
- $\sigma'(z) = \sigma(z)\cdot(1 - \sigma(z))$

Что на самом деле предсказывает $w^Tx + b$

$$p = \frac{1}{1 + e^{-z}}$$

$$\Longrightarrow \frac{p}{1 - p} = e^{z}$$

$$\Longrightarrow \log \frac{p}{1 - p} = z = w^{T}x + b$$

вероятность p	шансы p/(1−p)	log шансов
0.1	1 к 9	−2.2
0.5	1 к 1	0
0.8	4 к 1	1.4
0.99	99 к 1	4.6

Вероятность живёт в (0, 1), шансы — в (0, ∞), а log шансов — на всей прямой. Как раз как линейная модель.

Смысл весов: признак x_j вырос на 1 → log шансов вырос на w_j → шансы **умножились** на e в степени w_j.

Выход модели — вероятность

$$p(x) = \mathrm{P}(\, y = 1 \mid x \,) = \sigma(w^{\mathrm{T}} x + b)$$

«вероятность класса 1 при данных признаках»

Вероятностная модель

Модель не говорит «класс 1». Она говорит: метка — монетка, которая выпадает 1 с вероятностью $p(x)$.

Как понимать p = 0.8

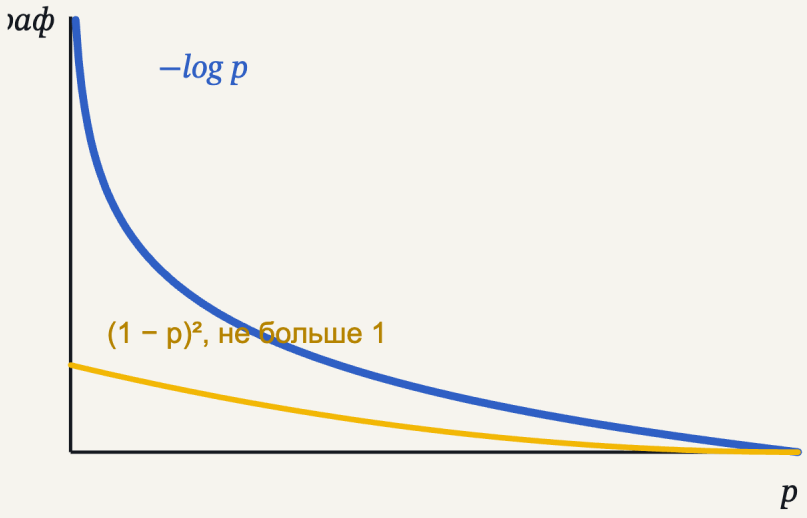
Среди многих похожих объектов примерно 80% окажутся классом 1..

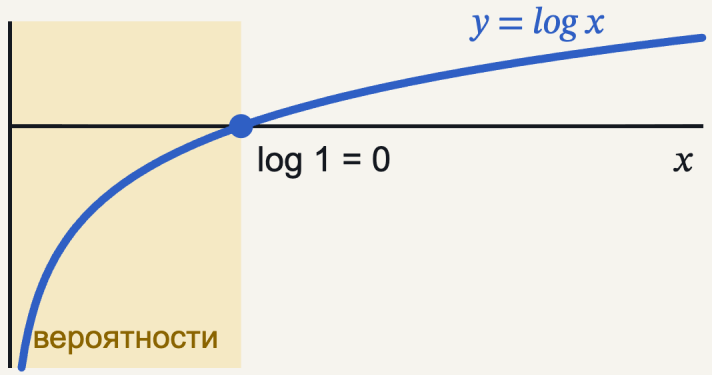
Зачем это нужно

Можно ранжировать объекты, выбирать порог, считать ожидаемый убыток: $p \cdot$ сумма.

Функция потерь: log-loss

$$L = -\sum_{i=1}^{N} [\, y_i \log p_i + (1 - y_i) \log(1 - p_i) \,]$$





На (0, 1) логарифм отрицателен и уходит в −∞ у нуля. Поэтому минус: штраф −log $p \geq 0$.

Кросс-энтропия

$$H(q, p) = -\sum_{k=1}^{K} q_k \cdot \log p_k$$

q_k — выключатель: 1 у верного класса, 0 у остальных

p_k — вероятность класса k от модели

q_k — выключатель: кошка: **q = 1 · ВКЛ** $-1 \cdot \log p$ | собака: **q = 0 · ВЫКЛ** $0 \cdot \log p = 0$ | птица: **q = 0 · ВЫКЛ** $0 \cdot \log p = 0$

K = 2: это ровно log-loss

классы 1 и 0: $q = (y, 1-y), p = (p, 1-p)$

$$H = -\sum_{k=1}^{2} q_k \log p_k = -[\, q_1 \log p_1 + q_2 \log p_2 \,]$$

$$= -[\, y \cdot \log p + (1-y) \cdot \log(1-p) \,]$$

Подставили $q_1 = y$, $q_2 = 1 - y$, $p_1 = p$, $p_2 = 1 - p$ — получили log-loss одного объекта.

Пример, K = 3

Верный класс — кошка:
q = (1, 0, 0)
модель: p = (0.7, 0.2, 0.1)

$$H = -1 \cdot \log 0.7 - 0 - 0 \approx 0.36$$

Нули в q гасят все слагаемые, кроме верного класса.

Градиент log-loss

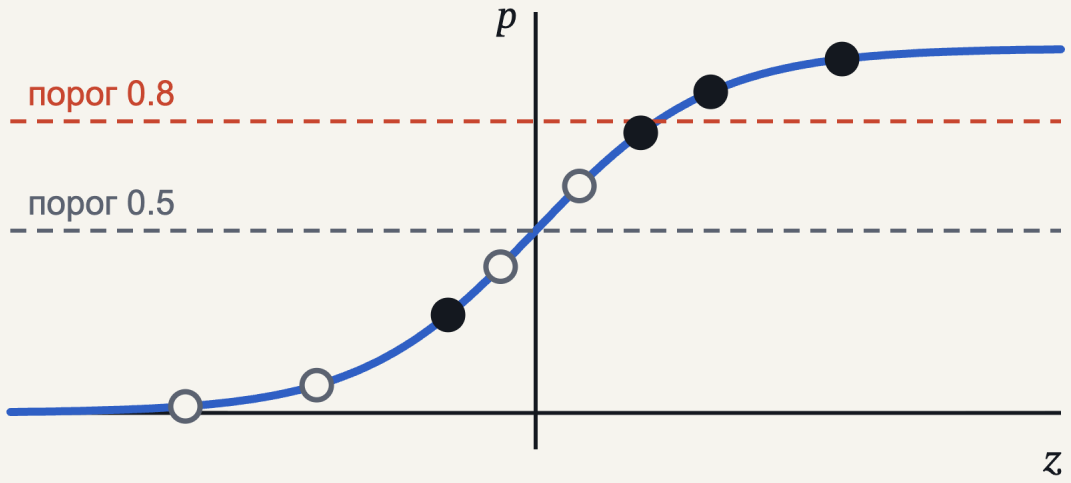
Для одного объекта, по цепочке через $\sigma' = \sigma(1 - \sigma)$:

$$\frac{\partial L}{\partial z} = p - y$$

$$\frac{\partial L}{\partial w_j} = \sum_{i=1}^{N} (p_i - y_i) \cdot x_{ij}$$

«Прогноз минус ответ» на признак — та же форма, что у MSE в линейной регрессии. Шаг: $w_j \leftarrow w_j - \alpha \cdot \partial L / \partial w_j$.

Вероятность и порог



Класс 1, если $p \geq t$.

Порог 0.5 — просто вариант по умолчанию. Его выбирают под задачу.

Порог выше → меньше ложных срабатываний, но больше пропусков.

Логрег целиком

1

Признаки

$x = (x1, \ldots, x_D)$

2

Линейная часть

$z = w^T x + b$

$=$ log шансов

3

Вероятность

$p = \sigma(z)$

4

Класс

1, если $p \geq t$

иначе 0

Обучение: подбираем w и b

лосс: $L = -\sum [\, y \log p + (1 - y) \log(1 - p) \,]$ (+ регуляризация)

градиент: $\partial L / \partial w_j = \sum (p - y) \cdot x_j$

шаг: $w_j \leftarrow w_j - \alpha \cdot \partial L / \partial w_j$

Порог t не участвует в обучении — его выбираем потом, под задачу.

Регуляризация в логреге

Штраф просто добавляется к log-loss:

$$L(w) = -\sum_{i=1}^{N} [\, y_i \log p_i + (1 - y_i) \log(1 - p_i) \,] + \lambda \sum_{j=1}^{D} w_j^2$$

В градиенте появляется слагаемое, которое тянет вес к нулю:

$$\partial L / \partial w_j = \sum_{i=1}^{N} (p_i - y_i) \cdot x_{ij} + 2\lambda w_j$$

Свободный член b

Не штрафуем: сумма по j идёт только по весам признаков.

L1 вместо L2

$\lambda \cdot \Sigma\, |w_j|$ — зануляет веса неважных признаков.

Зачем особенно

На разделимых данных без штрафа $w \to \infty$. Штраф держит веса конечными.

Accuracy и её границы

$$\text{Accuracy} = \frac{\text{число верных ответов}}{\text{все объекты}}$$

Ловушка дисбаланса

1000 пациентов, болеют 10. Модель «все здоровы» даёт accuracy 99% — и не находит ни одного больного.

Разная цена ошибок

Пропустить болезнь хуже, чем зря отправить на анализы. Accuracy считает эти ошибки одинаково.

Матрица ошибок

Факт ↓	Предсказание модели → 1	0
1	**TP** верно нашли	**FN** пропуск
0	**FP** ложная тревога	**TN** верно отсекли

верно ошибка

FP — ошибка I рода: спам-фильтр спрятал письмо от бабушки.

FN — ошибка II рода: тест не увидел болезнь.

T / F — угадали или нет.
P / N — что предсказала модель.

Accuracy = (TP + TN) / все.

Precision и recall

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

Из тех, кого назвали классом 1, какая доля правда класс 1?

«Не кричи зря»

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

Из всех настоящих объектов класса 1, какую долю нашли?

«Никого не пропусти»

F1 — среднее гармоническое

$$\mathrm{F1} = \frac{2 \cdot P \cdot R}{P + R} = \frac{2}{1/P + 1/R}$$

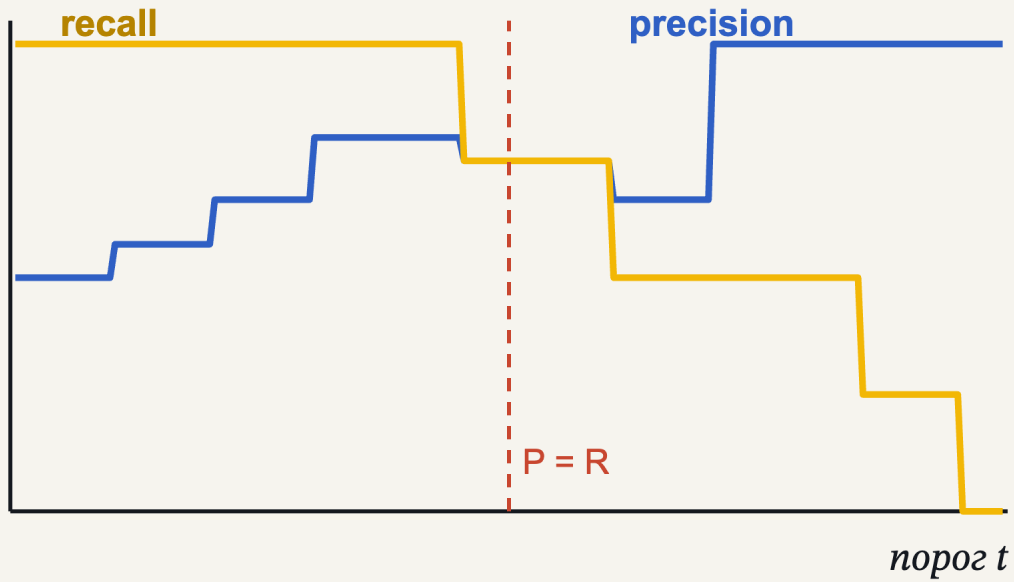
Почему не обычное среднее?

P = 1, R = 0.01 (нашли одного из ста). Среднее: 0.505 — выглядит прилично.

Гармоническое честнее

F1 = 2·1·0.01 / 1.01 ≈ 0.02. Близко к худшей из двух метрик — провал не замаскировать.

Как выбрать порог



Дорог пропуск (FN)

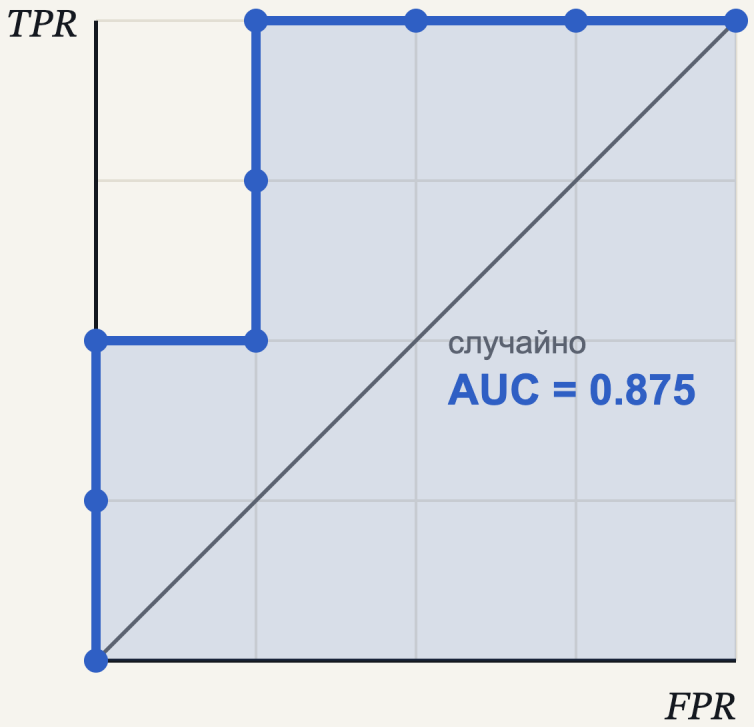
Онкоскрининг, фрод → порог ниже, растёт recall.

Дорога ложная тревога (FP)

Спам-фильтр, блокировка аккаунта → порог выше, растёт precision.

Нет предпочтений — точка, где P = R, или максимум F1.

ROC-кривая



$$\mathrm{TPR} = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FN}}$$

$$\mathrm{FPR} = \frac{\mathrm{FP}}{\mathrm{FP} + \mathrm{TN}}$$

Как строить: сортируем объекты по убыванию вероятности и опускаем порог с самого верха.

Встретили класс 1 → шаг **вверх** на 1/P.
Встретили класс 0 → шаг **вправо** на 1/N.

AUC — площадь под кривой.

Чему равен AUC

AUC = вероятность, что случайный объект класса 1 получит оценку выше, чем случайный объект класса 0

AUC = 0.5 — случайное угадывание, 1 — идеальная сортировка. Не зависит от порога и от любого монотонного преобразования оценок.

AUC — доля правильно упорядоченных пар

↓ оценка модели по убыванию

0.95	**класс 1**	**ниже неё нулей: 4 из 4**
0.85	**класс 1**	**ниже неё нулей: 4 из 4**
0.7	**класс 0**	
0.6	**класс 1**	**ниже неё нулей: 3 из 4**
0.45	**класс 1**	**ниже неё нулей: 3 из 4**
0.3	**класс 0**	
0.2	**класс 0**	
0.1	**класс 0**	

Сортируем объекты по оценке. Для каждой **единички** считаем, сколько **нулей** оказалось ниже неё — это правильно упорядоченные пары.

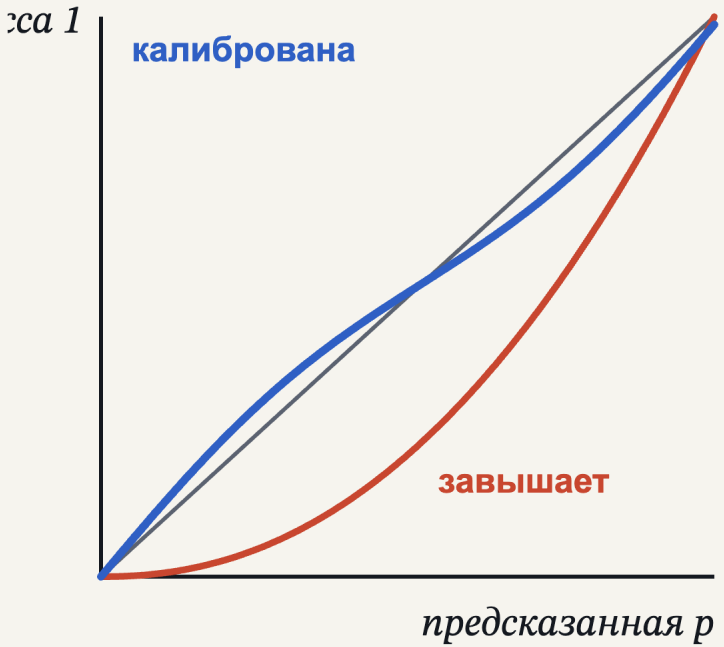
правильных пар: $4 + 4 + 3 + 3 = 14$

всего пар: 4 единички $\times$ 4 нуля $= 16$

$$\text{AUC} = 14 / 16 = 0.875$$

Идеальная модель: все единички выше всех нулей → AUC = 1. Случайная — 0.5.

Калибровка вероятностей



Модель калибрована, если среди объектов с $p \approx 0.8$ класс 1 действительно у ~80%.

Проверка: бьём объекты по корзинам предсказаний и сравниваем со средней долей класса 1.

Логрег на log-loss обычно калиброван неплохо. Бустинг, SVM, веса классов — ломают калибровку.

Чиним: Platt scaling (ещё одна сигмоида поверх) или изотоническая регрессия.

Взвешенные классы

Редкий класс тонет в log-loss: ошибок на нём мало, модель их почти не замечает.

$$L = -\sum_{i=1}^{N} \left[a_1 \cdot y_i \log p_i + a_0 \cdot (1 - y_i) \log(1 - p_i) \right]$$

Как выбрать веса

Часто обратно частоте: 10 больных из 1000 → вес больных в 99 раз больше.

Что получаем

Recall на редком классе растёт. Но вероятности завышены — калибровка сломана.

Focal loss

$$\mathrm{FL} = -(1-p)^{\gamma} \cdot \log p \quad (\text{для } y = 1)$$

Идея

Лёгкие объекты (уже угаданные уверенно) почти не дают вклада. Модель учится на трудных.

Пример, γ = 2

p = 0.9 → множитель $(0.1)^2 = 0.01$: штраф в 100 раз меньше. p = 0.5 → множитель 0.25.

γ = 0 — обычный log-loss. Придуман для детекции объектов, где фона в тысячи раз больше, чем объектов.

Много классов: как предсказывать

Три класса: 🐱 кошка, 🐶 собака, 🦪 птица. Пришла картинка — что ответить?

1. Один против всех

Учим 3 бинарных логрега: «кошка или нет?», «собака или нет?», «птица или нет?». Выбираем самого уверенного.

кошка или нет? → 0.7
собака или нет? → 0.4
птица или нет? → 0.1
Ответ: кошка

2. Каждый с каждым

Учим логрег на каждую пару классов. Каждый голосует за своего победителя.

кошка vs собака → кошка
кошка vs птица → кошка
собака vs птица → собака
2 голоса — кошка

3. Softmax

Одна модель сразу выдаёт вероятности всех классов, в сумме 1.

кошка → 0.67
собака → 0.24
птица → 0.09
Ответ: кошка

Итог всегда один: **берём класс с самой большой оценкой**.

Метрики для K классов

Факт ↓	Предсказание модели → кошка	собака	птица
кошка	8	1	1
собака	2	6	2
птица	0	1	4

верно ошибка

Смотрим на один класс как на бинарную задачу: **«кошка» против «не кошка»**.

TP — кошку назвали кошкой	8
FP — собаку назвали кошкой	2
FN — кошку назвали не кошкой	1 + 1 = 2

$$\text{Precision} = 8 / (8 + 2) = 0.8$$

$$\text{Recall} = 8 / (8 + 2) = 0.8$$

Так же — для собаки и птицы.

Как усреднить метрику по классам

класс	recall	объектов
кошка	0.8	10
собака	0.6	10
птица	0.8	5

Macro
все классы равны
$(0.8 + 0.6 + 0.8) / 3$
0.73

Weighted
вес = размер класса
$(10 \cdot 0.8 + 10 \cdot 0.6 + 5 \cdot 0.8) / 25$
0.72

Micro
все объекты в одну кучу
верных 18 / всех 25
0.72

Есть дисбаланс классов → смотрим **macro**: он не даёт маленькому классу потеряться.